



TC5035.10

Proyecto integrador

Planteamiento del proyecto

Segmentación semántica de cultivos en imágenes satelitales y generación automática de reportes mediante Deep Learning.

Dr. Gerardo Jesus Camacho Gonzalez, Dra. Grettel Barceló, Dr. Luis Falcón, Dr. Raúl Valente Ramírez

Equipo 13:

José Eduardo De Moraes López - A01634782

André Zaragoza Bonilla - A01797076

David Alejandro Velázquez Valdéz - A01632648

Tecnológico de Monterrey
Maestría en Inteligencia Artificial Aplicada

20/09/2026

Índice

1. Título del Proyecto y Justificación	3
2. Institución	4
3. Sector Industrial	5
4. Lugar de aplicación	6
5. Patrocinador o sponsor	7
6. Datos del sponsor	7
7. Dominio de aplicación	8
8. Plan de entregables	9
9. Repositorio del Proyecto	11
Referencias	13
Anexos	14

Segmentación semántica de cultivos en imágenes satelitales y generación automática de reportes mediante Deep Learning.

1. Título del Proyecto y Justificación

La agricultura juega un papel crucial en la seguridad alimentaria global, por lo que el monitoreo preciso de los cultivos y la predicción de su rendimiento son tareas de vital importancia. Con los desafíos climáticos y económicos actuales, tanto agricultores como gobiernos necesitan herramientas confiables para estimar la producción, optimizar recursos y proyectar cosechas. En este contexto, las imágenes satelitales permiten un análisis a gran escala; sin embargo, procesar manualmente esta vasta cantidad de información es inviable, lo que hace indispensable el desarrollo de sistemas automatizados capaces de interpretar estos datos geoespaciales. (National Aeronautics and Space Administration, s.f)



Fig 1 Imagen satelital de cosecha.

Por ello, el título refleja directamente la solución tecnológica a este reto. El núcleo del proyecto consiste en utilizar Deep Learning para realizar una "segmentación semántica", es decir, detectar y delimitar espacialmente las áreas sembradas a nivel de píxel. Sin embargo, el valor agregado del proyecto radica en la "generación automática de reportes". En lugar de entregar únicamente un mapa visual complejo de interpretar, el sistema traducirá los resultados cuantitativos (como el área total detectada) a texto en lenguaje natural, facilitando la comprensión de los datos.

Las aplicaciones de esta herramienta tienen un alto potencial de impacto. A nivel operativo, permite entregar información digerida y accionable a tomadores de decisiones que no necesariamente son expertos en Inteligencia Artificial o Sistemas de Información Geográfica (SIG). A mayor escala, este modelo puede servir como base para la estimación de subsidios agrícolas y sistemas de alerta temprana sobre escasez de alimentos, contribuyendo de manera directa a los Objetivos de Desarrollo Sostenible de la ONU, en particular al ODS 2

(Hambre Cero). Asimismo, al facilitar un monitoreo preciso del uso de suelo que permita la optimización de recursos, la herramienta impulsa el ODS 12 (Producción y Consumo Responsables), garantizando que el desarrollo de inteligencia artificial aplicada a la agricultura de precisión sirva como un motor activo para la sostenibilidad global. (Instituto Nacional de Estadística y Geografía, s.f)



Fig 2 ONU ODS 2 y 12.

2. Institución

Este proyecto se desarrolla bajo el marco de una colaboración de investigación internacional entre el Tecnológico de Monterrey (a través de su Departamento de Computación) y la Scuola Superiore Sant'Anna (mediante el Instituto de Inteligencia Mecánica, con sede en Pisa, Italia). Dado que es un proyecto de carácter científico y académico, las entidades que reciben el beneficio directo de la solución son los grupos de investigación de ambas instituciones, con el objetivo final de transferir este conocimiento al sector de la agricultura de precisión.

El Tecnológico de Monterrey es una de las instituciones académicas de mayor prestigio en América Latina, destacada por su fuerte enfoque en la innovación, el emprendimiento y la investigación aplicada. En este contexto, la iniciativa se consolida como el Proyecto Integrador de los estudiantes de la Maestría en Inteligencia Artificial Aplicada (MNA). A través de su Departamento de Computación, el Tec impulsa el desarrollo de soluciones tecnológicas avanzadas, permitiendo a los alumnos aplicar modelos de aprendizaje profundo en escenarios reales para resolver problemas complejos de la sociedad y fomentar la creación de conocimiento científico con impacto global. (Tecnológico de Monterrey, s.f)



Fig 3 Logo Tec de Monterrey

Por su parte, la Scuola Superiore Sant'Anna es una universidad pública de excelencia académica e investigación ubicada en Italia, reconocida internacionalmente por su labor pionera en ciencias aplicadas. El Instituto de Inteligencia Mecánica (Institute of Mechanical Intelligence) se especializa en la intersección de la robótica, la inteligencia artificial y la mecatrónica; su misión es desarrollar sistemas inteligentes que aborden los grandes retos contemporáneos, prestando especial atención a la sostenibilidad y a la optimización de procesos en sectores críticos como el agrícola. (Sant'Anna School of Advanced Studies, s.f)



Fig 4 Logo Scuola Superiore Sant'Anna

3. Sector Industrial

El proyecto se ubica en la intersección de la Investigación Científica y la Agricultura de Precisión. Para formalizar esta clasificación bajo un marco económico y estadístico estandarizado, el proyecto se alinea con el Sistema de Clasificación Industrial de América del Norte (SCIAN) México 2023. Adoptar este marco único y actualizado es fundamental, ya que permite homologar la información y asegurar su comparabilidad a nivel regional en América del Norte.

Bajo este catálogo, la aplicación directa de la solución se estructura de la siguiente manera:

- **Sector 11 - Agricultura, cría y explotación de animales, aprovechamiento forestal, pesca y caza:** Es el ecosistema general donde la herramienta de visión computacional tiene su impacto directo.

- **Subsector 111 - Agricultura:** Dado que el modelo de *Deep Learning* procesará imágenes satelitales (SITS) de diversas regiones, su capacidad de generalización le permite ser transversal a múltiples tipos de siembra, impactando principalmente en las siguientes ramas:
 - **1111:** Cultivo de semillas oleaginosas, leguminosas y cereales (como soya, trigo, maíz y arroz).
 - **1112:** Cultivo de hortalizas.
 - **1119:** Otros cultivos.

La importancia de utilizar este marco de clasificación radica en que la herramienta desarrollada no solo generará mapas visuales de segmentación, sino que producirá reportes textuales automatizados. Esta capacidad de traducir características espaciales en datos digeribles tiene el potencial de alimentar directamente las bases de datos de instituciones, facilitando la estimación de cosechas y la generación de estadísticas precisas para las categorías del SCIAN mencionadas, fortaleciendo así la toma de decisiones en el sector agroalimentario. (Instituto Nacional de Estadística y Geografía, s.f)



Fig 5 Logo SCIAN.

4. Lugar de aplicación

Debido a la naturaleza digital de las herramientas a desarrollar, el esquema de investigación colaborativa y la modalidad en línea del posgrado, el lugar de aplicación se define desde dos perspectivas: el entorno institucional de gestión y el alcance geográfico de la solución.

A) Entorno institucional y de desarrollo:

- **Ubicación institucional:** Ciudad de México, CDMX, México.
- **Área / Departamento:** Departamento de Computación del Tecnológico de Monterrey (Campus Santa Fe).

- **Modalidad de trabajo:** Desarrollo distribuido y remoto, en el marco de la Maestría en Inteligencia Artificial Aplicada (MNA) en modalidad en línea.
- **Colaboración académica:** Instituto de Inteligencia Mecánica de la *Scuola Superiore Sant'Anna* (Pisa, Toscana, Italia). Esta institución funge como socio metodológico y de investigación en las etapas iniciales y de diseño del proyecto.

B) Alcance geográfico de la solución (Testing y Aplicación):

- **Ubicación:** Territorio Nacional, México.
- **Justificación del alcance (Scope):** Aunque las arquitecturas de *Deep Learning* para la segmentación de imágenes satelitales son intrínsecamente escalables y pueden aplicarse en cualquier parte del mundo, el enfoque principal de este proyecto (pruebas, validación y métricas) se centrará en México. La herramienta será entrenada y evaluada priorizando datos geoespaciales de cultivos nacionales. Esto garantiza que el modelo resuelva necesidades locales tangibles en una primera fase, manteniendo la flexibilidad técnica para expandirse a nivel global en iteraciones futuras.

5. Patrocinador o sponsor

Dr. Gerardo Jesús Camacho González.

6. Datos del sponsor

- **Cargo actual:** *Research Professor* (Profesor Investigador) adscrito al Departamento de Computación.
- **Institución:** Tecnológico de Monterrey, Campus Santa Fe (Ciudad de México).
- **Correo electrónico institucional:** gjcamacho@tec.mx
- **Perfil académico y relación con el proyecto:** El Dr. Camacho González cuenta con un Doctorado (Ph.D.) en Tecnologías Digitales Emergentes y Robótica Perceptual por la *Scuola Superiore Sant'Anna* (Pisa, Italia), institución donde también se desempeñó como investigador posdoctoral. Cuenta con publicaciones científicas en áreas de visión computacional, detección de anomalías espaciales y sistemas inteligentes (como en *The International Journal of Advanced Manufacturing Technology*). Su

trayectoria académica es el puente directo de esta colaboración internacional y asegura el rigor metodológico necesario para el éxito técnico y científico del proyecto.

7. Dominio de aplicación

Selección: Visión computacional

El dominio predominante de este proyecto es la Visión Computacional, ya que constituye el motor algorítmico central y la principal carga de investigación metodológica. Aunque la arquitectura de la solución es multimodal y culmina en la creación automatizada de reportes textuales (lo que podría sugerir el uso secundario de *Procesamiento de lenguaje natural* o *IA generativa*), esta última fase es estructuralmente dependiente de la correcta extracción de características espaciales.

La elección de la Visión Computacional como dominio principal se fundamenta en los siguientes puntos:

- **Naturaleza del problema base:** El desafío científico radica en interpretar datos geoespaciales y multiespectrales en bruto provenientes de satélites. El modelo debe ser capaz de procesar estos arreglos complejos de píxeles para comprender la topología agrícola.
- **Carga arquitectónica (Deep Learning):** El desarrollo principal implicará diseñar, entrenar y evaluar arquitecturas neuronales especializadas en imágenes (como Redes Neuronales Convolucionales, U-Net, o *Vision Transformers*). La segmentación semántica —es decir, la clasificación y delimitación exacta de los cultivos a nivel de píxel— es la tarea computacionalmente más exigente y el verdadero *core* de la investigación.
- **Jerarquía de la información:** Es imposible redactar un reporte analítico sobre áreas de siembra, tipos de cultivo o proyecciones agrícolas si no existe primero un mapa de segmentación altamente preciso. El texto generado es simplemente la traducción a lenguaje natural del conocimiento profundo que la Visión Computacional extrajo previamente de la imagen.

Por lo tanto, al ser la base que habilita cualquier procesamiento posterior, la Visión Computacional rige el diseño, las métricas de evaluación (como *IoU* o *F1-Score*) y el éxito general del proyecto.




Fig 6 Segmentación semántica Cultivos.

8. Plan de entregables

El siguiente apartado presenta el cronograma estructurado de los entregables del proyecto. Este plan de trabajo toma como base la rúbrica oficial y el esquema de evaluación establecido para la unidad de formación de Proyecto Integrador. Su propósito es mapear de forma clara cómo se desarrollarán las actividades a lo largo del periodo académico, alineando los hitos obligatorios del curso con las fases de investigación, el desarrollo del modelo de Deep Learning y la escritura del artículo científico.

Entregable Oficial	Valor	Actividad Técnica (Visión Computacional y Texto)	Avance para el Paper (Hito Interno)
Planteamiento del proyecto (Semana 1)	5%	Definición del problema, justificación, sponsor y dominio.	Introducción: Motivación, ODS 2 y 12, y contribución principal.
Avance 0. Propuesta y convenios (Semana 2)	5%	Formalización del alcance en México y colaboración con Italia.	Target: Selección de revista/conferencia (ej. IEEE, MDPI).

Avance 1. Análisis exploratorio (Semana 3)	5%	Análisis de imágenes satelitales (SITS), distribuciones y máscaras agrícolas.	Trabajo Relacionado (SotA) y Datos: Descripción del dataset.
Avance 2. Ingeniería de características (Semana 4)	10%	<i>Data augmentation</i> , generación de recortes (<i>patches</i>) y alineación espacial.	Metodología (Preprocesamiento): Manejo de las imágenes.
Avance 3. Baseline (Semana 5)	10%	Entrenamiento de un modelo base de segmentación (ej. U-Net simple).	Metodología (Arquitectura): Descripción del modelo base.
Avance 4. Modelos alternativos (Semana 6)	10%	Pruebas con arquitecturas avanzadas (ej. <i>Vision Transformers</i>) e integración de texto.	Configuración Experimental: Métricas (IoU, F1-Score).
Avance 5. Modelo final (Semana 7)	10%	Selección del mejor modelo, ajuste de hiperparámetros y métricas finales.	Resultados y Discusión: Tablas comparativas y <i>Ablation Studies</i> .
Avance 6. Producto de difusión	10%	Empaquetado de la solución tecnológica.	Borrador final del Paper: Conclusiones y formato final.

(Semana 8)			
Avance 7. Resumen ejecutivo (Semana 9)	15%	Síntesis de los resultados clave y el impacto (reportes generados).	Abstract refinado: Versión ejecutiva de la investigación.
Presentación de proyecto (Semana 10-11)	15%	Defensa del proyecto ante el comité evaluador y el sponsor.	Material visual: Diapositivas tipo congreso científico.
Co-evaluación (Semana 11)	5%	<i>Evaluación interna del desempeño del equipo.</i>	<i>Coevaluación</i>
Total	100%		


Tabla 1 Plan de entregables Equipo 13

La estructuración de este plan se justifica por la necesidad de cumplir rigurosamente con los requerimientos institucionales, optimizando al mismo tiempo los esfuerzos del equipo hacia nuestra meta final de publicación. Al integrar el avance técnico como el análisis de imágenes satelitales, la experimentación con arquitecturas y la generación de texto directamente en las evaluaciones formales, garantizamos un progreso organizado, medible y validado paso a paso. Cabe destacar que, debido a la naturaleza empírica e iterativa de la investigación en Inteligencia Artificial, este cronograma se concibe como un documento dinámico y puede estar sujeto a cambios o ajustes conforme a los hallazgos experimentales, la disponibilidad de los datos o las recomendaciones del comité evaluador y el *sponsor*.

9. Repositorio del Proyecto

El repositorio del proyecto funcionará como espacio central de control de versiones y gestión integral de nuestra investigación. En esta plataforma se documentará de forma continua todo el progreso técnico y el stack tecnológico utilizado para el desarrollo de los modelos de Visión Computacional y generación de texto. Para garantizar el orden y la

reproducibilidad científica, el repositorio mantendrá una estructura clara que incluirá un archivo README principal con las instrucciones operativas e introducción al proyecto. Asimismo, albergará directorios específicos para la gestión de la data (imágenes satelitales SITS, máscaras y metadatos), las notebooks de experimentación (que contendrán el código de entrenamiento, validación y estudios de ablación), y finalmente, una carpeta de documentación, donde se resguardarán todos los entregables administrativos, reportes de evaluación y este documento de planeación.



Estructura

```

.
├── configs/           # Configuraciones del proyecto
├── data/              # Datos locales
│   ├── external/
│   ├── interim/
│   ├── masks/
│   ├── processed/
│   └── raw/
├── docs/              # Documentación y referencias
│   ├── onboarding/
│   ├── research/
│   └── schemas/
├── models/            # Modelos y checkpoints
│   └── checkpoints/
├── notebooks/         # Exploración y pruebas
├── reports/           # Métricas, figuras y resultados
│   ├── figures/
│   └── metrics/
├── scripts/           # Scripts ejecutables
├── src/segmentacion_cultivos_mx/ # Código fuente principal
├── tests/             # Pruebas básicas
└── third_party/       # Repositorios externos

```

Liga: <https://github.com/DavidVelazquez584/SegmentacionImagenesCultivoMexico.git>

Referencias

- Camacho Gonzalez, G. J. (s. f.). ORCID record. ORCID.
<https://orcid.org/0000-0001-9850-2524>
- Instituto Nacional de Estadística y Geografía. (s. f.). Sistema de Clasificación Industrial de América del Norte (SCIAN). <https://www.inegi.org.mx/scian/>
- Instituto Nacional de Estadística y Geografía. (s. f.). Sistema de Información de los Objetivos de Desarrollo Sostenible (SIODS). <https://agenda2030.mx/>
- Tarasiou, M., Chavez, E., & Zafeiriou, S. (2023). ViTs for SITS: Vision transformers for satellite image time series. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 10418–10428). IEEE.
<https://doi.org/10.1109/CVPR52729.2023.01004>
- Tecnológico de Monterrey. (s. f.). Tecnológico de Monterrey. <https://tec.mx/es>
- National Aeronautics and Space Administration. (s. f.). Soil Moisture Active Passive (SMAP). Jet Propulsion Laboratory, California Institute of Technology.
<https://smap.jpl.nasa.gov/>
- Sant’Anna School of Advanced Studies. (s. f.). Institute of Mechanical Intelligence.
<https://www.santannapisa.it/en/institute/mechanical-intelligence>
- Wen, S., Zhao, W., Ji, F., Peng, R., Zhang, L., & Wang, Q. (2025). “Phenology description is all you need!” Mapping unknown crop types with remote sensing time-series and LLM generated text alignment. ISPRS Journal of Photogrammetry and Remote Sensing, 228, 141–165. <https://doi.org/10.1016/j.isprsjprs.2025.07.002>

Anexos

Repositorio:

<https://github.com/DavidVelazquez584/SegmentacionImagenesCultivoMexico.git>

Carpeta de drive:

https://drive.google.com/drive/folders/1Xg_xveb83UIqovQ3d3pAyb3mnd9hV5LU?usp=sharing